

Báo Cáo GPU FinOps & Cost Optimization

Họ và tên: Trần Thượng Trường Sơn

MSSV: 2A202600313

Ngày nộp: 13/05/2026

1. Giới Thiệu

1.1. Mục tiêu của bài lab

Bài lab GPU FinOps (Financial Operations) & Cost Optimization giúp sinh viên nắm vững các khái niệm và kỹ năng thực hành trong việc quản lý chi phí GPU ở môi trường cloud computing. Sinh viên tiếp cận các công cụ và kỹ thuật để giảm chi phí vận hành mà vẫn đảm bảo hiệu suất tối ưu cho các workload training AI/ML.

1.2. Tổng quan về GPU FinOps

GPU FinOps là phương pháp quản lý tài nguyên GPU theo nguyên tắc tính chi phí và tối ưu hoá. Trong bài lab, chúng tôi sử dụng mock cluster với Docker Compose để mô phỏng môi trường cloud thực tế, bao gồm:

- GPU Cluster Monitoring:** Theo dõi trạng thái GPU nodes theo thời gian thực
- Cost Tracking:** Phân tích chi phí theo từng workload, node, và giai đoạn
- Spot Instance Management:** Quản lý Spot instances để tiết kiệm chi phí (tiết kiệm đến 70%)
- Autoscaling (KEDA-like):** Tự động điều chỉnh số lượng GPU theo nhu cầu
- Budget Management:** Dự báo chi phí và cấu hình cảnh báo

2. Phân Tích Từng Phần

2.1. Part 1: GPU Cluster Monitoring

Hệ thống cluster bao gồm **5 nodes** với **10 GPUs** thuộc 3 loại khác nhau. Kết quả thu thập được:

Thông tin các GPU nodes:

Node	GPU 0	GPU 1
node-00	T4 - 65.6% util, 11.3/16GB	T4 - 83.9% util, 11.0/16GB
node-01	A100 - 93.8% util, 63.4/80GB	A100 - 64.0% util, 43.0/80GB
node-02	V100 - 91.9% util, 16.8/32GB	V100 - 5.3% util, 0.6/32GB
node-03	T4 - 88.1% util, 13.3/16GB	T4 - 84.1% util, 11.4/16GB
node-04	T4 - 0.0% util, 0.5/16GB (idle)	T4 - 0.0% util, 0.5/16GB (idle)

Cluster Metrics Summary:

- Total GPUs: **10**
- Busy GPUs: **7**
- Idle GPUs: **3**
- Avg Utilization: **57.7%**
- Memory Used: **171.8 GB / 320.0 GB**
- Total Power Draw: **1026 W**
- Node Count: **5**

Insights:

- Có 3 GPU đang idle (node-04 hoàn toàn không sử dụng), đây là cơ hội tối ưu hoá chi phí
- GPU A100 trên node-01 có utilization cao nhất (93.8%), cho thấy workload nặng đang chạy
- Tổng công suất tiêu thụ 1026W cho thấy cluster đang hoạt động ở mức trung bình

2.2. Part 2: Workload Submission & Cost Tracking

Kết quả submit 4 workloads:

train-resnet-001: running → node-04, GPU 0
train-bert-002: running → node-02, GPU 1
inference-api-003: running → node-04, GPU 1
train-llm-004: queued → queued

- Sau khi submit: Busy GPUs: **10/10**, Utilization: **82.7%**

Billing Summary:

Workload	Type	Cost	Savings
train-resnet-001	ON-DEMAND	\$0.0292	\$0.0000
train-bert-002	ON-DEMAND	\$0.6117	\$0.0000
inference-api-003	SPOT	\$0.0035	\$0.0082

Workload	Type	Cost	Savings
train-llm-004	SPOT	\$0.5505	\$1.2845
Total		\$2.5589	\$2.7078

- Budget Used: **2.6%**
- Alert Status: **OK**

Nhận xét: Việc sử dụng Spot instances cho inference và LLM training giúp tiết kiệm đáng kể. Tổng savings \$2.7078 cho thấy chiến lược hybrid (On-demand + Spot) đã phát huy hiệu quả.

2.3. Part 3: Spot Instance Management

Bảng giá Spot hiện tại:

GPU Type	On-Demand	Spot Price	Discount	Availability
T4	\$0.35/hr	\$0.2773/hr	20.8%	low
A100	\$3.67/hr	\$2.7467/hr	25.2%	medium
V100	\$2.48/hr	\$1.9620/hr	20.9%	low

Spot Instance Requests:

- spot-t4-001(T4):  granted
- spot-t4-002 (T4):  granted
- spot-a100-001(A100):  granted

Spot Preemption & Savings Report:

Metric	Value
Spot cost	\$0.5015
On-demand equivalent	\$1.6715
Total saved	\$1.1701 (70.0%)

Phân tích:

- Discount spot cho A100 cao nhất (25.2%), mang lại tiết kiệm lớn nhất
- Tổng tiết kiệm 70% khi chuyển sang Spot instances
- Cần có chiến lược checkpointing để xử lý preemption

2.4. Part 4: Autoscaling (KEDA-like)

Autoscaling Policy Evaluation:

Initial state: Utilization 82.7% > threshold 70.0%
Action: SCALE_UP
Current utilization: 82.7%
Nodes: 5 → 6

5 Evaluation Cycles:

Cycle	Action	Util	Nodes
1	no_action	68.9%	6→6
2	no_action	68.9%	6→6
3	no_action	68.9%	6→6
4	no_action	68.9%	6→6
5	no_action	68.9%	6→6

Nhận xét:

- Sau khi scale up, utilization giảm xuống 68.9% (dưới threshold 70%), nên không cần thêm node
- Hệ thống tự động cân bằng giữa hiệu suất và chi phí
- Cooldown period hoạt động hiệu quả, tránh repeated scaling

2.5. Part 5: Cost Analysis & Optimization

Waste Analysis Report:

Metric	Value
Average Waste	6.2%
Total Idle Cost	\$0.026329
Total Cost	\$0.423330
Potential Monthly Save	\$682.45
Severity	LOW

Cost Optimization Recommendations:

Priority	Recommendation	Mô tả	Savings
MEDIUM	USE_SPOT	Chuyển fault-tolerant workloads sang spot instances	65.0%
LOW	SCHEDULING	Lên lịch training không khẩn cấp vào giờ thấp điểm	20.0%

Insights:

- Waste ở mức LOW (6.2%), cho thấy cluster được quản lý tốt
- Tiết kiệm tiềm năng \$682.45/tháng nếu áp dụng đầy đủ recommendations
- Ưu tiên 1: Chuyển sang Spot instances (dễ implement, savings cao)

2.6. Part 6: Visualization

Các biểu đồ visualization giúp nhận diện xu hướng và bất thường:

- **Cost Breakdown Chart:** Phân chia chi phí theo loại (compute, memory, network)
- **Time-series Tracking:** Theo dõi chi phí theo thời gian, phát hiện chi phí tăng đột biến
- **Waste Percentage:** Độ thi waste theo thời gian, giúp đánh giá hiệu quả tối ưu hoá

2.7. Part 7: Complete FinOps Workflow

Quy trình FinOps đầy đủ 7 bước:

Step	Nội dung	Kết quả
1	Initial cluster state	GPUs: 12, Util: 68.9%, Idle: 2
2	Submitting heavy workloads	Util: 81.7%, Busy: 12/12
3	Autoscaler evaluation	Decision: scale_up (81.7% > 70%)
4	Cost analysis	Cost: \$0.043889, Waste: 4.4%
5	Recommendations	USE_SPOT (65%), SCHEDULING (20%)
6	Applying optimization	Spot savings: \$0.0292 (70.0%)
7	Final billing	Spend: \$2.7280, Saved: \$2.8302, Budget: 2.7%

3. Part 8: Real GPU Workload Training

3.1. GPU Detection

Real GPU Detected:

Name: Tesla T4
Memory: 15.6 GB
Type: T4
Pricing: \$0.35/hr (on-demand)

CUDA: 12.8
pynvml: available

GPU Metrics Diagnostic:

Metric	Value
GPU Util	0% (idle before training)
Memory Total	16,106 MB (~16 GB)
Memory Used	472 MB
Power	10.4W
Temperature	46°C

3.2. FP32 vs Mixed Precision (AMP) Comparison

Chúng tôi thực hiện training model ResNet-18 trên CIFAR-10 để so sánh FP32 và AMP:

FP32 Training (Baseline):

Metric	Value
Epoch 1	Loss: 1.9566, Acc: 30.4%, Time: 40.3s
Epoch 2	Loss: 1.3788, Acc: 49.4%, Time: 42.4s
Epoch 3	Loss: 1.0700, Acc: 61.8%, Time: 45.0s
Total Time	127.7s
Peak Memory	0.82 GB
Avg GPU Util	95.5%
Avg Power	66.6W
Avg Temperature	71.3°C
Max GPU Util	99.0%
Estimated Cost	\$0.012412

AMP Training (Mixed Precision):

Metric	Value
Epoch 1	Loss: 1.9696, Acc: 29.1%, Time: 19.5s
Epoch 2	Loss: 1.3989, Acc: 48.5%, Time: 19.4s

Metric	Value
Epoch 3	Loss: 1.1015, Acc: 60.5%, Time: 19.6s
Total Time	58.5s
Peak Memory	0.60 GB
Avg GPU Util	91.3%
Avg Power	65.0W
Avg Temperature	76.6°C
Max GPU Util	94.0%
Estimated Cost	\$0.005687

So sánh chi tiết:

Metric	FP32	AMP	Cải thiện
Total Time	127.7s	58.5s	2.18x nhanh hơn
Peak Memory	0.82 GB	0.60 GB	0.22 GB tiết kiệm
Cost (USD)	\$0.012412	\$0.005687	\$0.006725 tiết kiệm
Cost Saving	-	-	54.2%
Final Accuracy	61.8%	60.5%	-1.3%

Extrapolated Savings at Scale:

Timeframe	FP32 Cost	AMP Cost	Tiết kiệm
1 day	\$8.40	\$3.85	\$4.55
1 week	\$58.80	\$26.94	\$31.86
1 month	\$252.00	\$115.47	\$136.53

Phân tích:

- Mixed Precision (AMP) giảm **54.2% chi phí** chỉ trong 3 epochs training
- Training time giảm **2.18 lần** nhờ tăng throughput
- Memory giảm 0.22 GB, cho phép sử dụng batch size lớn hơn
- Độ chính xác giảm không đáng kể (-1.3%), có thể chấp nhận được
- Với training 1 tháng, tiết kiệm được **\$136.53**

3.3. GPU Cost Reporting

Reporting to FinOps Gateway:

FP32 workload reported:
Cost: \$0.012400 | Rate: \$0.3500/hr

AMP workload reported (as spot):
Cost: \$0.001700 | Saved: \$0.004000

Final Dashboard (Mock + Real GPU):

Metric	Value
Total Platform Cost	\$2.7280
Total Savings	\$2.8302
Budget Utilization	2.7%
Alert	OK

4. Part 8.5: Advanced GPU Cost Optimization

4.1. Multi-GPU Scaling Efficiency

Phân tích chi phí khi sử dụng nhiều GPU (base: 2 giờ training trên 1 GPU A100 @ \$3.67/hr):

GPU Count	Speedup	Time (h)	Total Cost	Cost/Perf	Efficiency
1	1.00x	2.000	\$7.34	\$7.34	100.0%
2	1.80x	1.111	\$8.16	\$4.53	90.0%
4	3.40x	0.588	\$8.64	\$2.54	85.0%
8	6.00x	0.333	\$9.79	\$1.63	75.0% ← OPTIMAL

Nhận xét:

- Scaling efficiency giảm khi tăng số lượng GPU do communication overhead
- 8 GPUs là điểm tối ưu** về chi phí/hiệu suất (75% efficiency)
- Trên 8 GPUs, chi phí tăng nhanh hơn lợi ích về tốc độ
- Cost per performance giảm từ \$7.34 (1 GPU) xuống \$1.63 (8 GPUs) = **giảm 78%**

4.2. Project Cost Forecasting

Dự báo chi phí cho project training với 4 giai đoạn:

Phase	GPU	Số lượng	Giờ	Base Cost	Uncertainty
Data Preparation	T4	1	40h	\$14.00	±15%
Model Training	A100	4	120h	\$1,761.60	±25%
Hyperparameter Tuning	A100	8	60h	\$1,761.60	±30%
Model Evaluation	T4	2	20h	\$14.00	±10%

Financial Summary:

Metric	Value
Base Cost (expected)	\$3,551.20
Contingency (20%)	+\$710.24
Total with Contingency	\$4,261.44
95% Confidence Interval	[\$2,913.09 - \$5,609.79]
Worst Case (base+3σ)	\$5,614.99
Best Case (base-3σ)	\$1,487.41

Phân tích:

- Model Training chiếm ~50% chi phí (\$1,761.60)
- Confidence interval rộng (±47%) cho thấy uncertainty cao
- Cần buffer 20% contingency để phòng ngừa rủi ro
- Worst case (\$5,614.99) cao hơn 1.5 lần best case

4.3. Optimization Strategy Prioritization

Xếp hạng các chiến lược tối ưu hoá (baseline: 4x A100, 100h, FP32, On-demand = \$1,468.00):

#	Strategy	Savings	Effort	Risk	Score	Tiết kiệm (\$)
1	Switch to Mixed Precision (AMP)	25%	LOW	LOW	0.250	\$367.00
2	Use Spot Instances	60%	MEDIUM	HIGH	0.180	\$880.80
3	Optimize Batch Size	15%	LOW	LOW	0.150	\$220.20
4	Switch to More Efficient GPU Type	40%	HIGH	MEDIUM	0.107	\$587.20
5	Implement Early Stopping	20%	MEDIUM	LOW	0.100	\$293.60

Cumulative Savings Roadmap:

--

Strategy	Cumulative (\$)	Total Save %	Remaining Cost
AMP	\$367.00	25.0%	\$1,101.00
+ Spot Instances	\$1,027.60	70.0%	\$440.40
+ Batch Size	\$1,093.66	74.5%	\$374.34
+ GPU Type	\$1,243.40	84.7%	\$224.60
+ Early Stopping	\$1,288.32	87.8%	\$179.68

Quick wins: AMP + Batch Size optimization = **40% savings** với effort thấp

4.4. Challenge Exercise: LLM Fine-tuning Cost Optimization

Scenario:

- Project: Large Language Model Fine-tuning
- Baseline: 8x A100 trong 200 giờ
- Budget: \$5,000
- Deadline: 2 weeks (336h)

Baseline Cost: \$5,872.00 (vượt budget \$872.00 ❌)

Multi-GPU Analysis với 16 GPUs:

GPU Count	Speedup	Time (h)	Total Cost	Efficiency
1	1.00x	200.000	\$734.00	100.0%
2	1.80x	111.111	\$815.56	90.0%
4	3.40x	58.824	\$863.53	85.0%
8	6.00x	33.333	\$978.67	75.0%
16	10.56x	18.946	\$1,112.54	66.0% ← OPTIMAL

Optimization Applied:

- Chuyển 8x A100 → 16x A100 (optimal GPU count)
- Chuyển FP32 → AMP
- Hybrid: Spot cho batch, On-demand cho critical
- Early stopping + batch size tuning

Final Cost Forecast:

Metric	Value
--------	-------

Metric	Value
Optimized Base Cost	\$3,593.66
Contingency (15%)	+\$539.05
Total Forecast	\$4,132.71
Total Savings	\$2,278.34 (38.8%)
Under Budget?	YES
Deadline Check	NO (533.3h > 336h)

Kết luận Challenge:

- Vượt budget: tiết kiệm \$867.29 so với \$5,000
- Không đáp ứng deadline 2 tuần với 16 GPUs
- Đề xuất: giảm scope hoặc kéo dài deadline

5. Kết Luận Và Học Hỏi

5.1. Kỹ năng FinOps đã học

- Cost Awareness:** Hiểu rõ chi phí GPU là yếu tố quan trọng trong AI/ML projects
- Optimization Techniques:** Biết cách sử dụng AMP, Spot instances, autoscaling để giảm chi phí
- Forecasting:** Có khả năng dự báo chi phí, giúp lập kế hoạch tài chính tốt hơn
- Monitoring:** Thiết lập hệ thống monitoring để phát hiện waste sớm

5.2. Các chiến lược cost optimization hiệu quả nhất

Chiến lược	Tiết kiệm trung bình	Effort	Risk
Mixed Precision (AMP)	25-54%	Thấp	Thấp
Spot Instances	60-70%	Trung bình	Cao
Early Stopping	15-25%	Trung bình	Thấp
Batch Size Optimization	10-20%	Thấp	Thấp
GPU Type Selection	30-70%	Cao	Trung bình

5.3. Bảng tổng hợp chi phí GPU

GPU Type	On-Demand	Spot	Discount
T4	\$0.35/hr	\$0.2773/hr	20.8%
A100	\$3.67/hr	\$2.7467/hr	25.2%
V100	\$2.48/hr	\$1.9620/hr	20.9%

5.4. Ứng dụng thực tế trong projects

- **Small projects (< 50h):** Dùng T4 on-demand, AMP, early stopping
- **Medium projects (50-200h):** Kết hợp T4 + A100 Spot, autoscaling
- **Large projects (> 200h):** Full FinOps workflow, checkpointing, multi-GPU optimization

5.5. Recommendations

1. **Always use Mixed Precision (AMP)** - Gain free performance
2. **Start with smaller GPUs** - Upgrade only when needed
3. **Use Spot for non-critical training** - Save 60-70%
4. **Implement checkpointing** - Protect against preemption
5. **Set up budget alerts** - Prevent cost overruns
6. **Review waste weekly** - Continuous optimization

6. Hình Ảnh Minh Hoạ

Các hình ảnh minh hoạ được lưu trong thư mục `screenshots/` và `generated_charts/` :

- Cluster monitoring screenshots (Part 1)
- Cost breakdown charts (Part 6)
- FP32 vs AMP comparison (Part 8)
- Multi-GPU scaling efficiency (Part 8.5)
- Advanced FinOps dashboard (Part 8.5)
- Project forecast visualizations (Part 8.5)

7. Phụ Lục: Bảng Giá Tham Khảo

GPU Pricing (On-Demand vs Spot)

GPU	On-Demand (\$/hr)	Spot (\$/hr)	Savings
-----	-------------------	--------------	---------

GPU	On-Demand (\$/hr)	Spot (\$/hr)	Savings
T4	0.35	0.2773	20.8%
A100	3.67	2.7467	25.2%
V100	2.48	1.9620	20.9%

Training Cost Extrapolation (AMP trên T4)

Timeframe	Cost
Per epoch (3 epochs = 58.5s)	\$0.0057
1 hour	\$0.35
1 day	\$8.40
1 week	\$58.80
1 month	\$252.00

Kết luận: Bài lab đã cung cấp nền tảng kiến thức và kỹ năng thực hành quan trọng về GPU FinOps. Việc áp dụng những kỹ thuật tối ưu hoá chi phí đã học có thể giảm **50-88% chi phí GPU** trong các dự án AI/ML thực tế. Đặc biệt, Mixed Precision (AMP) là chiến lược "quick win" với hiệu quả cao nhất với effort thấp nhất.

Người thực hiện: Trần Thượng Trường Sơn
MSSV: 2A202600313
Ngày hoàn thành: 13/05/2026